

Big Data e inteligencia de negocios

Aspectos del Big Data, Apache Hadoop, bases analíticas y nube, relación con la estadística, inteligencia de negocios, modelo semántico, data marts e Integration Services.

Caso guía

Supermercados La Cosecha

6 ejercicios

Volumen · MapReduce · estadística ·
ETL · KPI

Eje

Ciudadanía planetaria con identidad

Subárea: Gestión empresarial para contadores · **Unidad de estudio:** Planificación y evaluación de proyectos (80 horas)

CTP Mercedes Norte · Especialidad de Contabilidad · Prof. Gerardo González González


Resultado de aprendizaje 5

Desarrollar técnicas que permitan el fortalecimiento de una ciudadanía planetaria con identidad.

Indicadores de logro (programa MEP)

- Explica la importancia de la Big Data en el contexto de una ciudadanía con identidad planetaria.
- Relaciona el Big Data con la estadística.
- Analiza la importancia de actuar con inteligencia en los negocios y la relaciona con su especialidad.
- Ejemplifica casos de inteligencia en los negocios.

Saberes esenciales



Caso guía

Supermercados La Cosecha S.A. tiene **12 tiendas** en Heredia y Alajuela. Cada día genera miles de facturas electrónicas, videos de seguridad y comentarios en redes. Quiere usar sus datos para decidir mejor.

Ejercicios resueltos

- 1. Dimensionar volumen, velocidad y variedad.
- 2. Contar ventas con MapReduce.
- 3. Estadística: media, mediana, correlación.
- 4. Diseñar un data mart.
- 5. Transformar datos (ETL).
- 6. Indicadores de BI y decisión.

Concepto

Big Data son conjuntos de datos tan grandes, rápidos o variados que no se pueden procesar con herramientas tradicionales (una hoja de cálculo o una sola computadora). Requiere almacenamiento y procesamiento **distribuido**.

Los tres aspectos (3 V)

Volumen

Cantidad: de gigabytes a terabytes y petabytes.

Velocidad

Rapidez con que llegan y deben procesarse: en tiempo real.

Variedad

Estructurados (tablas), semiestructurados (XML, JSON) y no estructurados (video, texto).

Hoy se agregan **veracidad** (calidad del dato) y **valor** (utilidad para decidir).

¿Qué tiene que ver con la ciudadanía planetaria?

Los datos permiten entender problemas **globales**: cambio climático, pandemias, pobreza, consumo de energía. Un ciudadano planetario usa la información para decidir de forma **responsable** con las personas y el ambiente.

Uso ético

- **Privacidad:** en Costa Rica, Ley 8968 de Protección de la Persona frente al tratamiento de sus datos personales (vigila la PRODHAB).
- **Consentimiento** informado del cliente.
- Evitar **sesgos** que discriminen.
- Los centros de datos consumen mucha **energía**.

Datos (supuestos del caso)

12 tiendas · 2 800 tiquetes por tienda al día · 12 líneas por tiquete · 500 bytes por línea · 16 cámaras por tienda que graban 0,5 GB por hora · en la hora pico se emite el 15 % de los tiquetes del día.

Volumen de ventas

$$\begin{aligned} \text{Líneas/día} &= 12 \times 2\,800 \times 12 = 403\,200 \\ \text{Bytes/día} &= 403\,200 \times 500 = 201\,600\,000 \\ &\approx 0,2\text{ GB por día} \approx 73,6\text{ GB por año} \end{aligned}$$

Volumen de video

$$12 \times 16 \times 24\text{ h} \times 0,5\text{ GB} = 2\,304\text{ GB/día} \approx 2,3\text{ TB}$$

Velocidad en hora pico

$$\begin{aligned} 15\% \times 12 \times 2\,800 &= 5\,040\text{ tiquetes/h} \\ 5\,040 \div 3\,600\text{ s} &= 1,4\text{ tiquetes/s} \end{aligned}$$

Variedad: clasificación de las fuentes

Fuente	Tipo
Ventas en la base de datos de cajas	Estructurado
Facturas electrónicas (XML)	Semiestructurado
Video de cámaras	No estructurado
Comentarios en redes sociales	No estructurado

Conclusión: las ventas solas no son Big Data; el video y la variedad de fuentes sí lo exigen.

¿Qué es Hadoop?

Plataforma **libre** de la fundación Apache para guardar y procesar grandes volúmenes de datos repartidos en **muchas computadoras comunes** (un clúster).

El núcleo de Hadoop

Componente	Función
HDFS	Sistema de archivos distribuido: divide y copia los datos en varios nodos
MapReduce	Modelo de programación: procesa en paralelo
YARN	Administra los recursos del clúster
Hadoop Common	Bibliotecas compartidas

Programabilidad y acceso a datos

Hive permite consultar con SQL; **Pig** con guiones simples; **HBase** da acceso rápido a registros; **Spark** procesa en memoria, mucho más rápido.

Ejercicio 2 · Enunciado

Cuente cuántas veces se vendió cada producto en 3 tiquetes:
T1: arroz, frijoles, café · T2: café, leche · T3: arroz, café

Solución

- 1 **Map:** cada línea emite (producto, 1): (arroz,1) (frijoles,1) (café,1) (café,1) (leche,1) (arroz,1) (café,1).
- 2 **Shuffle:** agrupa por clave: arroz [1,1] · café [1,1,1] · frijoles [1] · leche [1].
- 3 **Reduce:** suma cada grupo: **café 3 · arroz 2 · frijoles 1 · leche 1.**

Con millones de tiquetes, cada computadora hace el Map de una parte y luego se combinan: por eso es **rápido**.

Manejo y desarrollo de un proyecto de Big Data

- 1 Definir la **pregunta de negocio**.
- 2 Identificar y **capturar** las fuentes.
- 3 **Almacenar** (HDFS, nube).
- 4 **Limpiar** y transformar.
- 5 **Analizar** (estadística, modelos).
- 6 **Visualizar** y decidir.
- 7 **Proteger** los datos y cumplir la ley.

Sistemas integrados de Hadoop

Paquetes que reúnen Hadoop con herramientas de seguridad, administración y análisis. Ejemplos: **Cloudera** (que se fusionó con Hortonworks en 2019) y servicios administrados en la nube como **Amazon EMR** y **Google Cloud Dataproc**.

Mercados de Big Data (sectores que lo usan)

Comercio

Surtido, precios, promociones.

Banca

Detección de fraude.

Salud

Vigilancia de epidemias.

Gobierno

Control tributario y servicios.

Cómo es hoy

Muchas empresas ya no montan Hadoop en servidores propios: usan **Spark** y servicios **en la nube**. Hadoop sigue siendo la base conceptual.

Bases de datos analíticas

Diseñadas para **consultar y resumir** enormes cantidades de datos (no para registrar ventas una a una). Guardan los datos **por columnas**, lo que acelera sumas y promedios.

	Base transaccional	Base analítica
Uso	Registrar cada venta	Analizar millones de ventas
Consulta típica	Una factura	Ventas por mes y tienda
Ejemplos	Sistema de cajas, ERP	BigQuery, Redshift, Snowflake

Big Data en la nube

Se alquila almacenamiento y procesamiento a proveedores (AWS, Google Cloud, Microsoft Azure). Ventajas: se paga por uso, crece según la necesidad y no hay que comprar servidores.

Mercados de datos

Lugares donde se **compran, venden o comparten** conjuntos de datos: AWS Data Exchange o Snowflake Marketplace. También hay **datos abiertos** gratuitos: INEC y Banco Central de Costa Rica.

La Cosecha podría cruzar sus ventas con los datos de inflación del BCCR para ajustar precios.

Relación

El Big Data **recoge** los datos; la **estadística** los resume e interpreta: medidas de tendencia central y dispersión, correlación, muestreo y predicción.

8 semanas de la tienda Heredia Centro

Sem.	Promoción (€ miles)	Ventas (€ millones)
1	100	43
2	150	46
3	120	47
4	200	53
5	180	55
6	90	40
7	160	48
8	220	56

Solución (ventas)

Media = $388 \div 8 = 48,5$ millones
Mediana = $(47 + 48) \div 2 = 47,5$ millones
Desv. estándar (muestra) $\approx 5,73$ millones
Correlación promoción-ventas $r \approx 0,94$

Interpretación

r cercano a 1: cuando sube la promoción, **suben las ventas**. La recta de ajuste da ventas $\approx 30,9 + 0,115 \times$ promoción: con €250 000 se estimarían **€59,7 millones**.

Correlación no es causalidad: la semana 8 pudo coincidir con el pago de salarios. Además, 250 está fuera de los datos observados: es una estimación con riesgo.

Concepto

La **inteligencia de negocios** convierte datos en **información útil** (tableros, indicadores, informes) para **equipar a la organización** y tomar decisiones efectivas y oportunas.

Cómo se utiliza



La fuente de inteligencia empresarial

Fuente	Ejemplo en La Cosecha
Sistema contable / ERP	Ventas, costos, inventarios
Facturación electrónica	XML de compras y ventas
CRM y lealtad	Compras por cliente
Fuentes externas	Inflación (BCCR), población (INEC)

Herramientas

- **Power BI** (Microsoft)
- **Looker Studio** (Google, gratuito)
- **Tableau**
- Tablas dinámicas de **Excel**

BI en Contabilidad

Tableros de **márgenes por producto**, cuentas por cobrar vencidas, flujo de caja y comparación presupuesto vs. real. El contador pasa de **registrar** a **asesorar**.

Pregunta guía: ¿qué tienda vende más, cuál deja más margen y por qué?

Modelo semántico de BI

Capa que traduce las tablas técnicas a **lenguaje del negocio**: medidas (Ventas, Margen %), dimensiones (Tienda, Producto, Fecha) y jerarquías (Año > Mes > Día). En Power BI se llama así desde 2023 (antes “conjunto de datos”).

Data mart

Almacén de datos **pequeño y temático** (por ejemplo, solo ventas) para un área. Se organiza en **esquema estrella**: una tabla de **hechos** en el centro y tablas de **dimensiones** alrededor.

Desarrollo de la BI

- 1 Definir preguntas e indicadores.
- 2 Definir estructuras: hechos y dimensiones.
- 3 Crear el data mart.
- 4 Llenarlo con ETL.
- 5 Construir el modelo y los tableros.

Ejercicio 4 · Enunciado

Diseñe el data mart de ventas de La Cosecha con estos campos: fecha, mes, tienda, provincia, producto, categoría, cantidad, monto vendido, costo.

Solución: esquema estrella

Tabla	Tipo	Campos
Hechos_Ventas	Hechos (centro)	id_fecha, id_tienda, id_producto, cantidad, monto, costo
Dim_Fecha	Dimensión	fecha, mes, trimestre, año
Dim_Tienda	Dimensión	tienda, cantón, provincia
Dim_Producto	Dimensión	producto, categoría, proveedor

Regla: lo que se **suma** va en hechos (medidas); lo que **describe** va en dimensiones.

Integration Services (SSIS)

Herramienta de **SQL Server** para el proceso **ETL**: **extraer** de las fuentes, **transformar** y **cargar** en el data mart. Hoy, en la nube, la misma tarea se hace con **Azure Data Factory** o **Microsoft Fabric**.

Estructura y componentes

- **Paquete:** el proyecto ETL completo.
- **Flujo de control:** orden de las tareas.
- **Flujo de datos:** origen → transformadores → destino.
- **Administradores de conexión:** enlaces a las bases.

Transformadores frecuentes

Conversión de datos

Texto → fecha o número.

Columna derivada

Calcula campos nuevos.

Búsqueda (Lookup)

Trae el id de la dimensión.

División condicional

Separa filas por regla.

Ejercicio 5 · Datos de origen

Fecha	Tienda	Monto
05/10/2026	HER	€3 250
2026-10-05	spb	2 150
05/10/2026	HER	-3 250
05/10/2026	(vacío)	1 800

Solución: transformaciones

- 1 **Conversión:** todas las fechas a 2026-10-05.
- 2 **Columna derivada:** quitar "€" y espacios; tienda en mayúscula (spb → SPB).
- 3 **Lookup:** HER → id 1; SPB → id 2.
- 4 **División condicional:** monto negativo → tabla de **devoluciones**; tienda vacía → **bitácora de errores**.
- 5 **Carga:** 2 filas válidas al data mart (€3 250 y €2 150).

Consulta al data mart · octubre (€)

Tienda	Ventas	Costo	Margen bruto	Margen %	Tiq. prom.
Heredia Centro	185 000 000	138 750 000	46 250 000	25,0	5 968
San Pablo	142 000 000	109 340 000	32 660 000	23,0	5 358
Barva	98 000 000	72 520 000	25 480 000	26,0	5 000
Santo Domingo	121 000 000	93 170 000	27 830 000	23,0	5 990
Total	546 000 000	413 780 000	132 220 000	24,2	5 612

Margen % = (Ventas – Costo) ÷ Ventas × 100
Tiquete promedio = Ventas ÷ N.º de tiquetes
Tiquetes: 31 000 · 26 500 · 19 600 · 20 200 = 97 300

Análisis

- 1 **Heredia Centro** vende más y aporta el 35 % del margen.
- 2 **Barva** vende menos pero tiene el **mejor margen** (26 %).
- 3 **San Pablo y Santo Domingo** tienen el margen más bajo (23 %).

Decisión basada en datos

Revisar precios y mermas en San Pablo y Santo Domingo; copiar la mezcla de productos de Barva; en Santo Domingo, el tiquete alto sugiere clientes que compran mucho por visita: ofrecer programa de lealtad.

Comprobación: 46 250 000 ÷ 132 220 000 = 35,0 %.

Ejercicios

1. Una tienda vende ₡84 000 000 con 14 000 tickets. ¿Ticket promedio?
2. Ventas ₡50 000 000 y costo ₡38 000 000. ¿Margen %?
3. Clasifique por variedad: tabla de inventario, XML de factura, audio de llamadas.
4. MapReduce: T1 pan, leche · T2 pan · T3 leche, pan, huevos. ¿Resultado del Reduce?
5. En un data mart, ¿"monto vendido" y "provincia" son medida o dimensión?
6. ¿Qué ley protege los datos personales en Costa Rica?

Respuestas

1. $84\,000\,000 \div 14\,000 = \text{₡}6\,000$.
2. $(50 - 38) \div 50 = 24\%$.
3. Estructurado · **semiestructurado** · **no estructurado**.
4. **pan 3 · leche 2 · huevos 1**.
5. Monto vendido = **medida** (tabla de hechos); provincia = atributo de la **dimensión** Tienda.
6. **Ley 8968** (vigila la PRODHAB).

Recuerde

- 1 Big Data: **volumen, velocidad y variedad**.
- 2 Hadoop reparte datos (HDFS) y procesos (MapReduce) en un clúster.
- 3 Bases analíticas, nube y mercados de datos amplían el acceso.
- 4 La **estadística** convierte datos en conclusiones; correlación no es causalidad.
- 5 BI: fuentes → ETL → data mart → modelo semántico → tablero → decisión.
- 6 Hechos = lo que se suma; dimensiones = lo que describe.

Ciudadanía planetaria

Usar datos con **ética**: proteger la privacidad, evitar sesgos y aplicar la información a problemas comunes como el ambiente y la salud.

Cierre de la unidad

Planificar (RA 1), evaluar (RA 2), usar software (RA 3), equilibrar la vida (RA 4) y decidir con datos (RA 5).